

第四次作业：SVHN 模型的 INT8 静态量化

Deadline:

6 月 14 日前（含当天），将报告和源码打包成压缩文件，按照“姓名+学号+homework4”的格式发送到助教邮箱 zhek@mail.ustc.edu.cn。

（不需要包含数据集文件）

一、实验背景

在第二次作业中，我们通过 CNN 实现了 SVHN 街景数字分类任务，获得了 95% 以上的测试精度。但是在嵌入式设备等边缘场景中，FP32 模型的推理速度慢、功耗高，无法满足实时性要求。本次作业要求按照课程中所讲的线性量化原理，在第二次作业的基础上，实现完整的 INT8 线性量化流程，将训练好的 FP32 CNN 模型转换为 INT8 量化模型，并对比量化前后的精度、模型大小和推理速度，全面评估量化效果。

二、核心任务

1. FP32 基线模型

训练或加载一个 FP32 的 SVHN 分类模型（可以使用作业二中训练好的模型），并记录测试集准确率、模型大小以及 CPU 上单张图片推理延迟（取多次推理的平均值）。

2. 线性量化方法实现

手动编写量化与反量化的两个核心函数（不可直接调用库）：

1. `linear_quantize(x, num_bits=8)`：将浮点张量线性量化为整数张量。
2. `linear_dequantize(q, scale, zero_point)`：将整数张量反量化回浮点张量。

要求使用 per-tensor 非对称线性量化即可；per-channel 可自行尝试，该实验中不做要求。

3. INT8 静态量化（PTQ 训练后量化）

1. 量化节点插入：添加 `QuantStub` 和 `DeQuantStub`，标记模型输入的量化起始位置和模型输出的反量化结束位置。

2. 模型模块融合：融合 `Conv2d + ReLU` 和 `Linear + ReLU`，融合后的模块作为整体进行量化。
3. 设置量化配置：采用静态量化规则，激活值与权重均使用 per-tensor 非对称线性量化，与手动实现的量化函数保持一致。
4. 模型校准：从 SVHN 训练集抽取无标注样本作为校准集，使用校准集进行模型校准。
5. INT8 模型转换：将 FP32 模型转换为 INT8 推理模型，推理时自动完成量化 / 反量化。
6. 量化误差计算：对比 FP32 模型与 INT8 模型各层输出，计算每层量化 MSE 误差。
7. 模型评估：在测试集上评估 INT8 模型。

三、实验指标

报告中需要包含以下测试指标：

1. **精度指标**：量化前后模型的测试准确率对比，并计算精度损失
2. **模型大小**：量化前后模型大小对比，并计算压缩比
3. **推理速度**：CPU 上单张图片推理延迟对比（取多次推理的平均值）
4. **量化误差**：每层输出的量化 MSE 误差（量化层输出与原 FP32 层输出的均方误差）
5. **可视化结果**：绘制“量化前后精度对比图”和“量化前后推理延迟对比图”